

# 史上最可爱的关系抽取指南？从一条规则到十个开源项目

夕小瑶的卖萌屋 2019-12-29

以下文章来源于AINLP，作者太子長琴



**AINLP**

一个有趣有AI的自然语言处理社区：关注AI、NLP、机器学习、推荐系统、计算广告等相关技术。公众号可直接对话双语聊。

正文来自订阅号：AINLP

正文作者：太子長琴（NLP算法工程师）



小夕，我来给你出个题，看看你的反应如何？

好呀好呀，你说~



“梁启超有一个著名的儿子，叫梁思成;同时还有一个著名的学生，叫徐志摩。这两个人有一个共同的爱人，叫林徽因。林徽因的父亲是林长民，林长民不仅自己是名人，还有一个名人哥哥，叫林觉民。林徽因最后与梁思成结婚了，徐志摩娶的则是陆小曼。”

那么问题来了，梁启超和林长民是什么关系？

亲家！



哇，你怎么一口就答出来了！？

!?(·\_·)?

嘻嘻，我悄悄拿我的关系抽取模型跑了一下~(¬▽¬)"



啥是关系抽取？



呐，跟我来~！



信息抽取是NLP领域的一个经典任务了，如何从不同来源的自然语言文本中提取真实可用的“知识”，并保证这些“知识”通常是清楚的、事实性的信息，是当今信息抽取领域的一个难点。

信息抽取三个最重要/最受关注的子任务：

- **实体抽取**

也就是命名实体识别，包括实体的检测（find）和分类（classify）

- **关系抽取**

通常我们说的三元组（triple）抽取，一个谓词（predicate）带2个形参（argument），如  
location(IBM, New York)

Founding-

- **事件抽取**

相当于一种多元关系的抽取

属性一般的形式是（实体，属性，属性值），关系的一般形式是（实体，关系，实体）。简单来区分的话，关系涉及到两个实体，而属性只有一个实体。

不过呢，属性和关系的提取是可以相互借鉴的。下面小夕以关系抽取为出发点，从算法、数据集、评价指标、比赛这几个方面给大家介绍关系抽取的相关知识。文末还有一个蛋哦~~~~

## 关系提取方法

### 基于模板

这种方法比较简单，一般都是根据先验知识设计一些模式，然后在语料中匹配这些模式。举几个例子：

- 马云作为企业家，对应的模式是：XX(?:作为|是)YY

- 刘强东是京东的创始人，对应的模式是：`XX (?:作为|是) YY 的? ZZ`

这里的 XX YY 和 ZZ 自然就是前一步识别出来的实体了。

相关资源包括：

- 100 Best GitHub: Expert System | Meta-Guide.com

## 基于句法分析

主要是找到主谓宾，一般都是在句法分析的基础上进行的。举几个例子：

- 感冒是一种病，对应的句法结构为：感冒（SBV），是（Root），病（VOB）。
- 王思聪是王健林的儿子，对应的句法结构为：王思聪（SBV），是（Root），王健林（ATT），儿子（VOB）

其中，SBV 是主谓关系，VOB 是动宾关系，ATT 是定中关系。

相关资源包括：

- lemonhu/open-entity-relation-extraction: Knowledge triples extraction and knowledge base construction based on dependency syntax for open domain text.
- aoldoni/tetre: TETRE: a Toolkit for Exploring Text for Relation Extraction
- gabrielStanovsky/template-oie: Extract templated Open Information Extraction

## 基于机器学习

使用基本步骤如下：

- （通常在一个句子中）寻找实体对
- 判断实体对之间是否存在关系
- 送到分类器判断关系的类别（预先定义好的）是什么

标准流程：

- 预先定义好类别集合
- 选择相关实体集合
- 标注
- 设计特征
- 训练分类器
- 评估结果

特征：

- 词相关
- 词法相关

- 句法相关
- 实体相关

之前那篇笔记里涉及的比较全面，而且现在几乎都是结合深度学习模型做了，这块就不再赘述了。

相关资源：

- machinalis/iepy: Information Extraction in Python
- marcolagi/quantulum: Python library for information extraction of quantities from unstructured text

## 基于深度学习

一般包括两种做法：Pipeline 和 Joint model，前者就是把实体识别和关系分类分开；后者一起做。

特征一般是基于 Word embedding，Position embedding，POS，NER，WordNet；模型一般都是基于 CNN，RNN。

- 端到端目前最好的是基于 Bert 的，在此之前，最好的是 Wang et al. 2016 的 Multi-Attention CNN。
- 关系分类最好的是 (Cai et al., 2016) 的 BRCNN (Bidirectional Recurrent Convolutional Neural Network)。

从论文的趋势看，端到端相对主流一些，不过对于我们的需求来说，关系分类更适合些。更多相关论文和模型可以进一步阅读 [NLP-progress/relationship\\_extraction](#)，这里就不贴那些论文的东西了。

## 基于半监督

半监督是利用少量高精度的 pattern 种子或种子 tuple 来 bootstrap 一个分类器。具体而言，在大规模语料中查找包含已有 pattern 实体对的句子，然后提取和归纳实体的上下文来学习新的 pattern。

还是举个栗子，比如我们有一个种子 tuple：（Queen，创作了，波西米亚狂想曲），然后可能找到了这些句子：

- 波西米亚狂想曲是由 Queen 演唱的歌曲。
- 波西米亚狂想曲是 Queen 最伟大的作品之一。
- Queen 这首将近 6 分钟的波西米亚狂想曲包括四个部分。

进而可以提取出类似这样的一些 pattern：

- （艺人，演唱，歌曲）
- （歌曲，是，艺人，作品）
- （艺人，作品，包括）

这些 pattern 又可以进一步寻找新的 pattern（把艺人和歌曲替换掉）。最终算法如下：

```

1  function BOOTSTRAP(Relation R) returns new relation tuples
2  tuples←Gather a set of seed tuples that have relation R
3  iterate
4  sentences←find sentences that contain entities in tuples
5  patterns←generalize the context between and around entities in sentences
6  newpairs←use patterns to grep for more tuples
7  newpairs←newpairs with high confidence
8  tuples←tuples + newpairs
9  return tuples

```

Bootstrapping 系统会给新的 pattern 一个置信度以避免语义飘移。比如“在演唱会现场粉丝的要求下，周杰伦不得不演唱了一首网络歌曲《学猫叫》”，（周杰伦，演唱，学猫叫）显然不是我们想要的。关于置信度的计算可以参考上面提到的笔记，对一个 pattern 主要考量两方面因素：pattern 在现有 tuple 上的 hits 和在整个 Documents 上的 finds。

## 基于远程监督

远程监督从大规模数据库中获取的大量种子中产生出许多带噪声的 pattern features，然后用一个分类器组合这些 pattern。

举个栗子，比如要学习“出生地-出生日期”关系，半监督的方法中，我们可能只有少量几个启动的种子，但是现在我们可以在 Wikipedia-based 数据库(比如 DBPedia 或 Freebase) 中获取大量包含“出生地-出生日期”的 tuple，比如( <Albert Einstein, Ulm>, <Hubble, Marshfield> 等等)。然后用命名实体工具提取包含两个实体并 match 给定 tuple 的句子：

- Hubble 出生于 Marshfield
- Einstein，生于 1879，Ulm
- Hubble 的出生地是 Marshfield

可以从中提取训练集，一个训练实例对应一个（关系，实体1，实体2）。

- <出生地, Edwin Hubble, Marshfield>
- <出生地, Albert Einstein, Ulm>
- <出生日期, Albert Einstein, 1879> ☐

接下来可以用基于特征的分类器或直接使用神经网络分类器（不需要构建特征）。对于前者，可以从多个方面构建特征，比如实体 label, 实体间单词、路径, 相邻词等。每个 tuple 包括多个训练实例的特征, 每个实例又可以从多个句子中获取词法和句法特征。最终的算法如下：

```

1  function DISTANT SUPERVISION(Database D, Text T) returns relation classifier C
2  foreach relation R
3  foreach tuple (e1,e2) of entities with relation R in D
4  sentences←Sentences in T that contain e1 and e2
5  f←Frequent features in sentences
6  observations←observations + new training tuple (e1, e2, f, R)
7  C←Train supervised classifier on observations
8  return C

```

最终的分类器将会根据特征发现关系。

基于无监督

无监督关系提取的目的就是在没有标注数据,甚至没有任何关系列表的情况下从 Web 或大规模语料中提取关系。这个任务一般叫 open information extraction 或 Open IE, 关系通常都是几个单词 (常以动词开头)。

ReVerb 系统从一个句子中提取关系一般包括四步:

- 在句子上进行 POS 和实体识别。
- 对句中每个动词, 找到以动词开头并满足句法和词汇约束 (合并相邻匹配项) 的最长单词序列  $w$ 。
- 对每个短语  $w$ , 找到最左边的名词短语  $x$  (不是相对代词, wh-单词或 “there”), 在右边找到最近的名词短语  $y$ 。
- 使用置信度分类器 (一个逻辑回归分类器) 给关系  $r=x, w, y$  一个置信度。

分类器是在 1000 个随机选择的句子上训练所得, 首先提取关系, 然后人工标注是否正确, 最后训练分类器。使用到的一些特征如下 (将提取到的关系及周围的词作为特征):

1	(x,r,y) covers all words in s
2	the last preposition in r is for
3	the last preposition in r is on
4	len(s) ≤ 10
5	there is a coordinating conjunction to the left of r in s
6	r matches a lone V in the syntactic constraints
7	there is preposition to the left of x in s
8	there is an NP to the right of y in s

小结

方法	优点	缺点
模板	精准高, 领域内可定制	召回低, 耗时耗力
句法分析	构建简单	召回低, 与句法结果相关
机器学习	数据相关时精准较高	特征工程较复杂, 数据标注成本较高, 训练数据敏感
深度学习	数据相关时精准高, 泛化能力较好	数据标注成本很高, 训练数据敏感
半监督 Bootstrapping	成本低, 可以发现新关系	对初始种子敏感, 语义飘移, 准确率低
远程监督	精准高, 训练数据不敏感, 无语义飘移	依赖已有数据库
无监督	成本很低, 容易实现	需转为权威格式存储, 动词为中心的局限性

比赛

比赛最有名的大概就是 SemEval 2018 Task 10 和 SemEval-2010 Task 8 了。前者是一个二分类任务, 目的是识别给定属性能否区分两个给定的概念。

ATTRIBUTE	CONCEPT1	CONCEPT2	LABEL
bookcase	fridge	wood	1

bucket ATTRIBUTE	mug CONCEPT1	round CONCEPT2	0 LABEL
angle	curve	sharp	1
pelican	turtle	water	0
wire	coil	metal	0

后者是关系分类任务，给定两个标记的 nominals，预测它们的关系和关系的方向。

There were apples, **pears** and oranges in the **bowl**.

(content-container, pears, bowl) ☐

## 数据集

除了上面的两个比赛的数据集，还有以下一些数据集：

- FewRel: A Large-Scale Supervised Few-shot Relation Classification Dataset with State-of-the-Art Evaluation
  - 70K sentences
  - 100 relations
  - Wikipedia corpus
- The New York Times Annotated Corpus - Linguistic Data Consortium
  - Stanford NER 提取实体
  - 自动与 Freebase knowledge base 中的实体关联
  - 关系也是基于 Freebase knowledge base 中的事实
- Stanford TACRED Homepage
  - 106,264 examples
  - newswire and web text from TAC KBP Comprehensive English Source Corpora 2009-2014 - Linguistic Data Consortium
  - 41 relation types as used in the TAC KBP challenges

## 评价方法

评价指标还是以 F1 为主：

- 属性判别是二分类任务，直接用 F1 评估。
- 关系分类使用 Macro-averaged F1（9 个关系，不包括 OTHER，考虑关系方向）。
- FewRel 主要是在 5-way-1-shot, 5-way-5-shot, 10-way-1-shot 和 10-way-5-shot 几个任务上的准确率。
- NYT 主要使用 N 个结果的精准率或 PR 图。
- TACRED 使用 Micro-averaged F1（不包括 no\_relation type）。

## 更多资源

CrowdTruth Corpus 相关：

- CrowdTruth/CrowdTruth-core: CrowdTruth framework for crowdsourcing ground truth for training & evaluation of AI systems
- CrowdTruth/Open-Domain-Relation-Extraction: Crowdsourced data for open domain relation classification from sentences

- CrowdTruth/Medical-Relation-Extraction: Crowdsourced ground truth for medical relation extraction.

#### 其他资源：

- roomylee/awesome-relation-extraction: A curated list of awesome resources dedicated to Relation of the most important tasks in Natural Language Processing (NLP).
- NLP-progress/relationship\_extraction.md at master · sebastianruder/NLP-progress

#### 参考资料：

- 知识抽取-实体及关系抽取 - 徐阿衡 知乎
- 知识图谱入门 (三) 知识抽取 - pelhans 的博客



明天有「超级超级重磅」的文章放出噢！小伙伴们记得提前做好准备鸭(¬\_¬)

---

声明：pdf仅供学习使用，一切版权归原创公众号所有；建议持续关注原创公众号获取最新文章，学习愉快！